

SLURM调度系统 管理和使用介绍

HPC产品事业部

吕灼恒、张涛、郝文静

目录



- 01 调度系统概述
 - 基本概念

■ 主要作用

■ 功能特性

■ 运行架构

- 02 安装部署介绍
- 03 用户使用介绍
- 04 日常管理介绍
- 05 常见问题处理

调度系统概述-基本概念



■ 资源 (Resource)

- ✓ 作业运行过程中使用的可量化实体都是资源;
- ✓ 包括硬件资源(节点、内存、CPU、GPU等)和软件资源(License);

■ 集群 (Cluster)

- ✓ 包含计算、存储、网络等各种资源实体且彼此联系的资源集合;
- ✓ 在物理上,一般由计算处理、互联通信、I/O 存储、操作系统、编译器、 运行环境、开发工具等多个软硬件子系统组成;
- ✓ 节点是集群的基本组成单位,从角色上一般可以划分为管理节点、登陆节点、计算节点、存储节点等。

■ 作业 (Job)

- ✓ 物理构成,一组关联的资源分配请求,以及一组关联的处理过程;
- ✓ 交互方式,可以分为交互式作业和非交互式作业;
- ✓ 资源使用,可以分为串行作业和并行作业;

调度系统概述-基本概念(续)



■ 分区 (Partition)

- ✓ 带名称的作业容器;
- ✓ 用户访问控制;
- ✓ 资源使用限制;

■ 作业调度系统 (Job Schedule System)

- ✓ 负责监控和管理集群中资源和作业的软件系统;
- ✓ 通常由资源管理器、调度器、任务执行器,以及用户命令和API组成;

调度系统概述-主要作用



- 单一系统映像
 - ✓ 解决集群结构松散问题;
 - ✓ 统一用户接口,使用简化;
- 系统资源整合
 - ✓ 管理异构资源和异构系统;
- 多任务管理
 - ✓ 统一管理任务,避免冲突;
- 资源访问控制
 - ✓ 基于策略的资源访问控制;

调度系统是面向集群的操作系统。

调度系统概述-功能特性



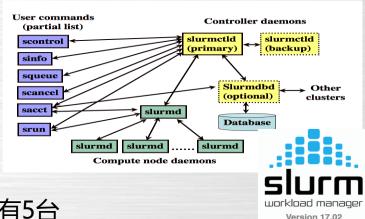
IBM Blue Gene/Q Cray XT

天河超级计算机 硅立方

IBM_Sequoia

.... S





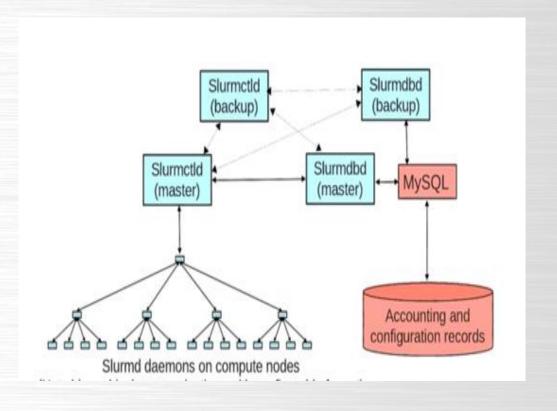
SLURM调度核心 -2016年6月Top500前十名有5台

- ◆ 高性能;
- ◆ 灵活性(众多插件);
- ◆ 扩展性很高,支持数百万处理器核心的调度;
- ◆ 节点容错, 高稳定性;
- ◆ 安全性高、易移植性 (不修改内核) 好;
- ◆ 支持各种常用的HPC操作系统(AIX、Linux、Solaris);
- ◆ MPI支持较好,作业抢占、进程/线程绑定、作业依赖等轻松支持;
- ◆ 网络拓扑调度,内置支持Tree、3D-Tours等多种算法。

调度系统概述-运行架构

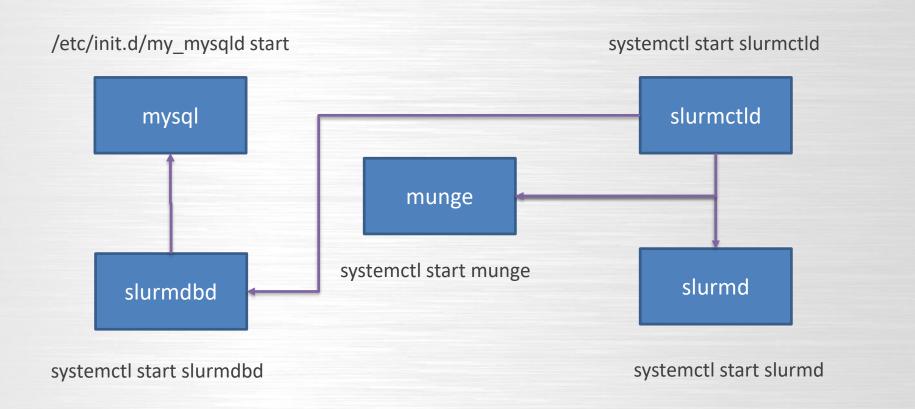


- 主控服务slurmctld 故障切换 资源监控 队列管理 作业调度
- 记账存储服务slurmdbd 记账数据 配置信息 故障切换
- 数据库MySQL 记账和配置信息存储
- **计算代理slurmd** 启动任务 监控任务 分层通信
- **认证服务**munge 内部通信认证



调度系统概述-服务启动





目录



- 01 调度系统概述
- 02 安装部署介绍
 - 角色与服务
 - 配置管理

- 目录结构
- 日志管理

- 03 用户使用介绍
- 04 日常管理介绍
- 05 常见问题处理

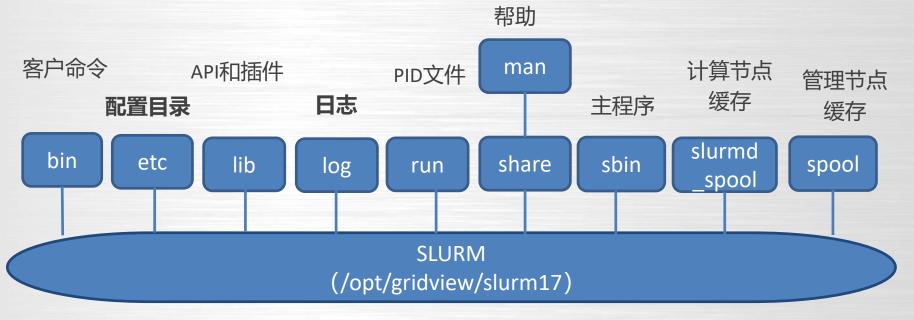
安装部署-角色与服务



角色类型	节点范围	软件路径	服务名称
登陆节点	gv0001~gv0010,共计 10个节点	1. 调度软件安装目录/opt/gridview,包括 munge、 slurm17	munge.service
管理节点	gvm03 (主用) gvm04 (备用)	1. 调度软件安装目录/opt/gridview,包括munge、slurm17 2. 数据库软件/gvdata/mysql-5.6.38-linux-glibc2.12-x86_64	munge.service slurmctld.service slurmdbd.service rsyncd和同步脚本
计算节点	gvm0011~gvm1538,共 1528个节点	1. 调度软件安装目录/opt/gridview,包括munge、slurm1	munge.service slurmd.service
MySQL节点	gvm05 (主用) gvm06 (备用)	1. 调度软件主目录/opt/gridview,包括munge、slurm17 2. 数据库软件 /gvdata/mysql-5.6.38-linux-glibc2.12-x86_64	my_mysqld

安装部署-软件目录结构





说明:

- 1. 所有节点的配置目录etc需要借助共享存储全局共享 (/g1/gv_share/pia_etc)
- 2. 主备节点之间需要同步spool目录实现高可用(/opt/gridview/slurm17/spool)

安装部署-配置文件概述



配置类型	文件名称	主要内容	其它说明
主配置文件	slurm.conf	包含主要的调度配置参数,包括调度策略、运行配置、日志配置、记账采集、权限控制、容错配置、认证方式、作业前后处理等等。	必选
记账存储服务配 置文件	slurmdbd.conf	包含slurmdbd使用的配置参数,包括认证方式、 权限控制、运行配置、日志配置和数据库访问 配置。	必选
节点配置文件	slurm_node.conf	包含所有计算节点的配置参数,如节点名、 CPU核数、内存、默认状态等。	可选,可合并到 slurm.conf
分区配置文件	slurm_partition.conf	包含所有分区的配置参数,如分区名、节点列表、优先级、合法账号、默认时间、默认内存、 默认状态等。	可选,可合并到 slurm.conf
拓扑配置文件	topology.conf	包含所有节点与交换机以及交换机之间的层次网络链接关系。	可选,由参数 TopologyPlugin=topolo gy/tree控制
通用资源配置文 件	gres.conf	定义计算节点包含的GRES资源,如名称、类型、设备等。	可选,由参数 GresTypes和Gres控制

伤于成就梦想

安装部署-主配置文件slurm.conf



#集群名称 ClusterName=cluster_gvm03 #主用节点 ControlMachine=gvm03 #备用节点 BackupController=gvm04 AuthType=auth/munge #内部认证 #加密方式 CryptoType=crypto/munge #最大作业数20万 MaxJobCount=200000 #提交参数过滤 JobSubmitPlugins=lua KillOnBadExit=1 #异常作业清理 ProctrackType=proctrack/linuxproc #进程跟踪插件 #禁用自动恢复 ReturnToService=1 #主控服务端口 SlurmctldPort=6817 #计算代理端口 SlurmdPort=6818 #slurmctld运行用户 SlurmUser=slurmadm SlurmdSpoolDir=/opt/gridview/slurm17/slurmd_spool/ # 计算代理缓存 StateSaveLocation=/opt/gridview/slurm17/spool # slurmctld本地文件缓存 #拓扑调度 TopologyPlugin=topology/tree

#任务启动cpuset TaskPlugin=task/affinity MinJobAge=300 #完成作业保留时 间 SlurmctldTimeout=30 #主备切换时间 #计算代理响应时 SlurmdTimeout=300 间 #快速调度作业 FastSchedule=1 SchedulerType=sched/backfill #启用回填 #调度器端口 SchedulerPort=7321 #资源选择算法 SelectType=select/cons_res SelectTypeParameters=CR Core Memory #基于 Core和内存调度 SchedulerParameters=batch_sched_delay=3,defer,sche d_min_interval=10,sched_interval=30,default_queue_ depth=100,bf_max_job_test=100,bf_interval=30 # 调 度参数 AccountingStorageTRES=cpu,mem #TRES指标配置

安装部署-主配置文件slurm.conf



#优先级策略 PriorityType=priority/multifactor #半衰期时长 PriorityDecayHalfLife=30 #FS统计间隔 PriorityCalcPeriod=5 PriorityWeightFairshare=100 #FS权重 #分区权重 PriorityWeightPartition=1000 #集群名 ClusterName=pia #抢占策略 PreemptMode=requeue,gang PreemptType=preempt/partition_prio #队列优先级 #调试标识 DebugFlags=NO_CONF_HASH PrivateData=accounts, events, jobs, reservations, usage, us #权限控制 HealthCheckInterval=60 #检查间隔 #检查工具 HealthCheckProgram=/usr/sbin/nhc AccountingStorageEnforce=associations,limits #组织 关联和资源限制

AccountingStorageHost=gvm04 #主用记账服务 AccountingStorageBackupHost=gvm03 #备用记账服务

AccountingStoragePort=7031 #记账服务端口

AccountingStorageType=accounting_storage/slurmdbd #启用slurmdbd AccountingStorageUser=root #记账服务

AccountingStoreJobComment=YES #记录作业注释
JobCompType=jobcomp/none #禁止生成comp日志
JobAcctGatherFrequency=300 #作业采集间隔
JobAcctGatherType=jobacct gather/linux #启用

Linux插件

SlurmctldDebug=3 #日志级别 SlurmctldLogFile=/opt/gridview/slurm17/log/slurmctld. log

JobRequeue=1 # 允许重新排队

SlurmdDebug=3 #日志级别

SlurmdLogFile=/opt/gridview/slurm17/log/slurmd_%h.

log

SuspendTime=1800 #

include slurm_node.conf #引入节点配置 include slurm_partition.conf #引入分区配置

携手成就梦想

安装部署-记账存储服务配置slurmdbd.conf



AuthType=auth/munge # 内部认证类型 # slurmdbd服务节点 DbdHost=gvm04 #备用服务节点 DbdBackupHost = gvm03 #记账存储服务监控端口 DbdPort=7031 #运行用户 SlurmUser=slurmadm #日志级别 DebugLevel=3 PrivateData=accounts,events,jobs,reservations,usage,users # 权限控制 #日志路径 LogFile=/opt/gridview/slurm17/log/slurmdbd.log StorageType=accounting_storage/mysql #启用mysql #数据库主机 StorageHost=gvm05 #数据库备机 StorageBackupHost=gvm06 #数据库端口 StoragePort=3308 #密码 StoragePass=root #用户名 StorageUser=root #数据库示例 StorageLoc=gv slurm db

安装部署-节点配置slurm_node.conf



NodeName=cmac[0011-0260] NodeAddr=cmac[0011-0260] CPUs=32 Boards=1 SocketsPerBoard=2 CoresPerSocket=16 ThreadsPerCore=1 RealMemory=385437 State=UNKNOWN NodeName=cmac[0261-1538] NodeAddr=cmac[0261-1538] CPUs=32 Boards=1 SocketsPerBoard=2 CoresPerSocket=16 ThreadsPerCore=1 RealMemory=191913 State=UNKNOWN

可选参数:

MemSpecLimit: 保留内存的大小 Weight: 节点权重,用于节点选择 Feature: 节点特征,用于节点选择

Gres: 通用资源(如GPU), 如 GRES=gpus:2

Reason: 节点状态异常 (down、drain、fail等) 时的原因。

State:可选的状态包括DOWN、FAIL、FAILING、UNKNOWN、BUSY、IDLE、CLOUD、FUTURE。

不要直接配置成BUSY (报错)和IDLE,而应该配置为UNKNOWN (默认)。

注意事项:

1. 节点配置的变更需要同时重启slurmctld和slurmd服务

安装部署-分区配置slurm partition.conf



Nodes=cmac[0011-0034] Priority=1000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=ALL DefaultTime=15-00:00:00 MaxTime=INFINITE DefMemPerCPU=10240 LLN=YES State=UP Nodes=cmac[0011-0034] Priority=1000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=nwp_nwp_op,nwp_sp,lijuan,nwp_pd,nwp_qu DefaultTime=15-00:00:00 MaxTime=INFINITE DefMemPerCPU=10240 LLN=YES State=UP Nodes=cmac[0035-0260] Priority=1000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=ALL QOS=normal_qos DefaultTime=15-00:00:00 MaxTime=INFINITE DefMemPerCPU=10240 S PartitionName=largemem tate=UP PartitionName=normal Nodes=cmac[0035-1538] Priority=1000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=ALL QOS=normal qos DefaultTime=15-00:00:00 MaxTime=INFINITE DefMemPerCPU=5120 Stat

PartitionName=operation Nodes=cmac[0035-1538] Priority=2000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=nwp,nwp_op,nwp_sp,lijuan,nwp_pd,nwp_qu,nwpbj_ex DefaultTime=15-00:00:00 MaxTime=IN FINITE State=UP

参数简介:

OverSubscribe:

EXCLUSIVE:独占节点,即使启用了elect/cons res

FORCE[:X]:强制节点(在X作业间)共享,忽略用户自身请求

YES: 允许作业共享,考虑用户--oversubscribe 请求。

PreemptMode:

队列级的抢占模式,覆盖全局配置

PriorityJobFactor:

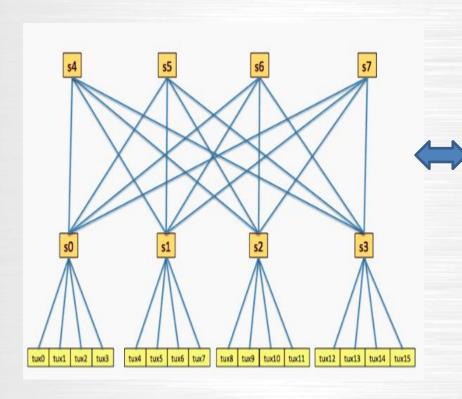
用于multifactor Priority。

State:

UP(正常) DOWN(接收不调度) DRAIN(调度不接收) INACTIVE (DOWN+DRAIN)

安装部署-拓扑配置示例





```
# topology.conf
# Switch Configuration
SwitchName=s0 Nodes=tux[0-3]
SwitchName=s1 Nodes=tux[4-7]
SwitchName=s2 Nodes=tux[8-11]
SwitchName=s3 Nodes=tux[12-15]
SwitchName=s4 Switches=s[0-3]
```

配置格式:

- (1) 交换机-节点 SwitchName=X Nodes=<node name>
- (2) 交换机-交换机
 SwitchName=X Switches=<switch name>

安装部署-拓扑配置topology.conf



.

SwitchName=ibsw97

Nodes = gv0942, gv0934, gv0941, gv0933, gv0940, gv0932, gv0939, gv0931, gv0946, gv0938, gv0945, gv0937, gv0944, gv0936, gv0943, gv0935, gv0949, gv0939, gv0939, gv0931, gv0946, gv0938, gv0945, gv0937, gv0944, gv0936, gv0943, gv0935, gv0949, gv0939, gv0939, gv0946, gv0938, gv0948, gv09

SwitchName=ibsw98

Nodes=gv0926,gv0918,gv0925,gv0917,gv0924,gv0916,gv0923,gv0915,gv0930,gv0922,gv0929,gv0921,gv0928,gv0920,gv0927,gv0919,gv0893,gv0894

SwitchName=ibsw99

Nodes=gv0910,gv0902,gv0909,gv0901,gv0908,gv0900,gv0907,gv0899,gv0914,gv0906,gv0913,gv0905,gv0912,g v0904,gv0911,gv0903,gv0883,gv0884

SwitchName=ibsw102 Switches=ibsw3,ibsw2,ibsw1

SwitchName=ibsw103 Switches=ibsw4,ibsw6,ibsw5

SwitchName=ibsw104 Switches=ibsw9,ibsw7,ibsw8

SwitchName=ibsw105 Switches=ibsw12,ibsw11,ibsw10

•••••





■ 支持通用资源,必须在slurm.conf配置文件中明确 指定要管理哪些资源。

参数	解释
GresTypes	e.g. <i>GresTypes=gpu,mic</i>
Gres	e.g. Gres=gpu:tesla:2,gpu:kepler:2

安装部署-通用资源配置gres.conf



参数	解释
Name	通用资源的名称(必须与slurm.conf 中的GresTypes值匹配)
Count	此节点上可用的此类型资源数。默认 值为1
CPUs	指定可以使用该资源的CPU index number
File	e.g. File=/dev/nvidia[0-3]
Туре	指定设备类型。

安装部署-日志管理概述



■ 日志文件范围

主控服务slurmctld 记账存储服务slurmdbd

计算代理服务slurmd 认证服务munge

■ 日志级别参数

配置参数:

Slurm.conf: SlurmctldDebug SlurmdbdDebug

slurmdbd.conf: DebugLevel

日志级别:

调度系统支持的日志级别包括:

quiet	fatal	error	info	verbos e	debug	debug2	debug3	debug4	debug5
0	1	2	3	4	5	6	7	8	9

■ 日志转储设置

通过操作系统的logrotate工具管理实现自动的日志滚动保存。

安装部署-日志文件说明



日志文件:

- **主进程日志slurmctld.log** 存在于调度系统管理节点的/opt/gridview/slurm17/log目录,记录主进程运行日志,涉及作业提交、 作业调度、作业控制、状态监控等各个方面的正常和异常信息。
- **记账存储服务日志slurmdbd.log** 存在于调度系统管理节点的/opt/gridview/slurm17/log目录,主要记录跟数据库相关的各种操作日志。
- **计算代理日志slurmd_{hostname}.log** 存在于调度系统计算节点的/opt/gridview/slurm17/log目录,记录计算节点服务的运行日志。
- **认证服务日志munged.log** 存在于每一个调度相关节点的/opt/gridview/munge/log/munge/munged.log目录, 主要记录调度系统各组件通信过程中产生/销毁各种凭证 (credential) 的日志。

安装部署-日志转储设置



转储配置:

通过三个logrotate配置文件分别实现slurmctld/slurmdbd、slurmd、munge服务的日志文件转储。

日志转储配置	节点分布	对应服务
/etc/logrotate.d/slurm	管理节点	主控服务slurmctld 记账存储服务slurmdbd
/etc/logrotate.d/slurmd	计算节点	计算代理slurmd
/etc/logrotate.d/munge	所有节点	认证服务munged

手工测试:

logrotate -f /etc/logrotate.d/slurmd

安装部署-日志转储设置-主服务转储配置



```
/opt/gridview/slurm17/log/slurmdbd.log
/opt/gridview/slurm17/log/slurmctld.log
                   #启用gzip压缩
   compress
               #日志不存在不报错退出
   missingok
                 #转储不清空
   nocopytruncate
                 #转储时立即压缩
   nodelaycompress
                  #禁用邮件通知
   nomail
                  #为空时不转储
   notifempty
                  #原目录保存
   noolddir
                  #保存3个转储文件
   rotate 3
                  #多个文件同时处理
   sharedscripts
   daily
                  #转储周期
                  #转储后缀为年月日
   dateext
                  #条件大于200M
   size 200M
```

```
# 文件转储后的操作
postrotate
   for daemon in $(scontrol show daemons)
    do
        killall -SIGUSR2 $daemon
    done
    ps -fe|grep slurmdbd |grep -v grep
   if [ $? -ne 0 ]
    then
      echo "no slurmdbd process"
    else
      killall -SIGUSR2 slurmdbd
   fi
endscript
```

安装部署-日志转储设置-计算代理转储配置



```
/opt/gridview/slurm17/log/slurmd_*.log
                  #启用gzip压缩
   compress
   missingok
              #日志不存在不报错退出
                 # 转储不清空
   nocopytruncate
   nodelaycompress
                 #转储时立即压缩
                 #禁用邮件通知
   nomail
                 # 为空时不转储
   notifempty
                 #原目录保存
   noolddir
                 #保存3个转储文件
   rotate 3
                  #多个文件同时处理
   sharedscripts
                  #转储周期
   daily
                 #转储后缀为年月日
   dateext
                 #条件大于50M
   size 50M
```

```
#文件转储后的操作
postrotate
   for daemon in $(scontrol show daemons)
   do
       killall -SIGUSR2 $daemon
   done
 endscript
```

安装部署-日志转储设置-认证服务转储配置



```
/opt/gridview/munge/log/munge/*.log
                 #启用gzip压缩
   compress
              #日志不存在不报错退出
   missingok
   nocopytruncate
                 # 转储不清空
                 #转储时立即压缩
   nodelaycompress
                 #禁用邮件通知
   nomail
                 # 为空时不转储
   notifempty
                 #原目录保存
   noolddir
                 #保存3个转储文件
   rotate 3
                 #多个文件同时处理
   sharedscripts
                 #转储周期
   daily
                 #转储后缀为年月日
   dateext
                #条件大于50M
   size 50M
```

```
# 文件转储后的操作
postrotate
    ps -fe|grep munged |grep -v grep
    if [ $? -ne 0 ]
    then
         echo "no munged process"
    else
         killall -SIGUSR2 munged
    fi
endscript
```

目录



- 01 调度系统概述
- 02 安装部署介绍
- 03 用户使用介绍
 - 命令用法介绍

■ 作业提交示例

- 04 日常管理介绍
- 05 常见问题处理

命令概述(1/3)



命令分类	命令	功能介绍
	sbatch	提交脚本排队执行, 批处理模式。
	salloc	创建资源申请并启动shell用于运行作业,交互 模式
作业提交和控制	srun	创建资源申请并启动作业步(通常是MPI作业)。
	sattach	连接正在运行的作业步的标准输出和错误等。
	scancel	取消作业或作业步。
	sinfo	查看节点和分区的状态。
系统状态	squeue	查看作业和作业步的状态。
カラし1人心	scontrol	查看或更新各种对象(如集群、分区、作业、 作业步、预约等)的状态。

命令概述(2/3)



命令分类	命令	功能介绍			
	sacct	报告作业/作业步的记账信息。			
>コロレルナ、	sstat	报告正在运行的作业/作业步的信息,包含状态采集。			
记账统计	sreport	从集群、分区、用户、账号等角度统计资源使 用情况。			
	sacctmgr	调度数据库配置管理工具,包括集群、用户、 账号等增删,以及资源限制策略的配置。			
调度配置	sprio	查看作业优先级的具体构成因素。			
炯 凌읩 旦	sshare	查看各账号的公平共享相关数据。			
	sdiag	显示调度模块的操作统计信息,包括运行周期、 作业状态统计、RPC类型统计等等。			

房于成就多想

命令概述(3/3)



命令分类	\$	功能介绍			
	sbcast	在作业中传输特定的文件到分配的计算节点中。			
甘宁今今	strigger	事件触发器管理工具。			
其它命令	smap	图形化的查看作业、节点等状态信息。			
	sview	图形化的查看系统(作业、分区、预约等)的状态,修改系统配置。			



sinfo命令参数(1/3)					
-a,all	查看所有分区信息(含隐藏分区),对应环境变量SINFO_ALL。				
-d,dead	查看dead状态(通信异常)的节点和分区的信息,与-r参数对应。				
-h,noheader	打印分区 (或节点) 信息时不打印表头。				
-i <seconds>, iterate=<seconds></seconds></seconds>	定时打印状态信息。				
-l,long	打印分区 (或节点) 的详细信息。				
-n <nodes>, nodes=<nodes></nodes></nodes>	查看指定节点的信息。				
-N,Node	以面向节点(默认为分区)的格式打印信息,每行一个节点。				
-p <partition>, partition=<partition></partition></partition>	查看指定分区的状态,对应环境变量SINFO_PARTITION。				



sinfo 命令参数介绍(2/3)					
-r,responding	查看计算节点(内部通信)正常的节点和分区的状态,与-d参数对应。				
-R,list-reasons	查看节点不可用的原因,包括管理操作设置的异常。				
-s,summarize	查看分区中节点状态的摘要信息。				
-S <sort_list>,</sort_list>	设置打印状态信息时排序的规则,如sinfo -S "#P, -t"。参数可以通过设置				
sort= <sort_list></sort_list>	环境变量SINFO_SORT实现。				
-t <states>,</states>	查 询 指 定 节 点 状 态 的 分 区 或 节 点 的 信 息 , 常 见 状 态 包 括 :				
states= <states></states>	ALLOC/ALLOCTED,COMP/COMPLETING,DOWN,DRAIN/DRAINED/DRAI				
	NING,ERR/ERROR,FAIL,IDLE,MIX/MIXED,UNK/UNKNOWN。				
federation	显示所有集群的分区(或节点)的信息,对应变量SINFO_FEDERATION。				
local	仅显示当前集群的分区(或节点)的信息,对应环境变量SINFO_LOCAL,				
	优先级高于federation。				
-M,clusters= <string></string>	显示多个集群的分区(或节点)的 信息,对应环境变量SLURM_CLUSTERS。				

取值 "割" 代表所有生群



Sinfo参数介绍 (3/3)

-o <output_format>,

按照指定的字段和格式显示信息,对应变量SINFO_FORMAT。

--format=

格式为 "%[[.]size]<type> %[[.]size]<type> ..."。

<output_format>

其中,点号(.)表示右对齐,size表示字段长度,type为代表特定字段的字符

(或字符串)。示例如下:

sinfo -o %all 以竖线分隔的形式显示所有字段。

sinfo -o "%9P %.5a %.10l %.6D %.6t %N"

显示内容: 分区名-分区状态-最大运行时间-节点数-节点状态-节点列表。

-O <output_format>,

按照指定的格式显示状态信息。

--Format=

格式为"type[:[.]size],type[:[.]size],..."。

<output_format>

其中,type为代表特定字段的字段名,点号(.)表示右对齐,size表示字段长

度。示例如下:

sinfo -O all

sinfo -O Partition:9,available:.6,time:.11,nodes:.6,statecompact:.6,nodelist:.12



格式化字段说明(1/5)			格式化字段说明 (2/5)		
字段名	格式化	字段说明	字段名	格式化	字段说明
(-O)	(-0)		(-O)	(-0)	
allocmem		节点已分配内存	disk	%d	临时盘大小MB
allocnodes	%S	队列提交节点	features	%f	节点属性
available	%a	分区状态	features_act	%b	Active features
cluster	%V	集群名	groups	%g	分区用户组
cpus	%с	节点CPU核数	gres	%G	一般性资源
cpusload	%O	节点负载	maxcpuspernode	%В	单节点最大核数
freemem	%e	节点空闲内存	memory	%m	节点总内存
cpusstate	%C	CPU统计A/I/O/T	nodes	%D	节点数
cores	%Y	Cores/Socket	nodeaddr	%o	节点地址
defaulttime	%L	默认运行时间	nodeai	%A	节点统计A/I



格式化字段说明(3/5)			格式化字段说明(4/5)		
字段名	格式化	字段说明	字段名	格式化	字段说明
(-O)	(-0)		(-O)	(-0)	
nodeaiot	%F	节点统计AIOT	reason	%E	节点不可用原因
nodehost	%n	节点主机名列表	root	%r	仅root可用资源
nodelist	%N	节点名列表	size	% s	作业节点数限制
oversubscribe	%h	资源超额认购	statecompact	%t	节点状态,缩写
partition	%P	分区名	statelong	%T	节点状态
partitionname	%R	分区名	sockets	%X	节点Socket数
port		节点TCP端口	socketcorethread	%z	CPU配置, S:C:T
preemptmode	%M	分区抢占模式	time	%l (L)	最大运行时间
priorityjobfactor	%l (i)	分区优先级因子	timestamp	%H	节点不可用时间
prioritytier	%p	分区调度优先级	threads	%Z	单核超线程数

查询信息-查询命令sinfo



格式化字段说明(5/5)						
字段名 (-O) 格式化 (-o) 字段说明						
user	%u	节点不可用状态的配置用户				
userlong	%U	同user,额外显示用户ID				
version	% v	软件版本				
weight	%w	节点优先级				
all	%all	全体字段,竖线分隔				



示例1: 默认格式查看分区的状态信息。

等价于 sinfo -o "%9P %.5a %.10l %.6D %.6t %N"

```
[sghpc2@login04 ~]$sinfo
PARTITION AVAIL TIMELIMIT
                            NODES
                                   STATE NODELIST
serial
                  infinite
                                    idle cmac[0011-0030]
normal
                  infinite
                                1 drain* cmac1174
             up
                                   drain cmac[1091-1173,1175-1282,1304]
normal
                  infinite
             up
normal
                  infinite
                                   alloc cmac[0035-0048,0057-0088,0094-0101]
             up
                  infinite
                                    idle cmac[0049-0056,0089-0093,0102-1090,1283-1303,1305-1538]
normal
             up
operation
                  infinite
                                1 drain* cmac1174
             up
                  infinite
operation
                                   drain cmac[1091-1173.1175-1282.1304]
             up
operation
                  infinite
                                  alloc cmac[0035-0048,0057-0088,0094-0101]
             up
                                    idle cmac[0049-0056,0089-0093,0102-1090,1283-1303,1305-1538]
operation
                  infinite
             up
                  infinite
                               54 alloc cmac[0035-0048,0057-0088,0094-0101]
sqtest
             up
                  infinite
                                    idle cmac[0049-0056,0089-0093,0102-0835]
sgtest
                              747
[sghpc2@login04 ~]$
```

示例2: 长格式查看分区的状态信息(--long / -l)。

等价于 sinfo -o "%9P %.5a %.10l %.10s %.4r %.8h %.10g %.6D %.11T %N"

```
[sghpc2@login04 ~]$sinfo --long
Tue Mar 27 22:51:58 2018
PARTITION AVAIL TIMELIMIT JOB SIZE ROOT OVERSUBS
                                                       GROUPS NODES
                                                                           STATE NODELIST
                 infinite l-infinite
                                                          all
                                                                           mixed cmac0011
serial
                 infinite 1-infinite
                                                                  19
                                                                           idle cmac[0012-0030]
normal
                 infinite 1-infinite no
                                                NO
                                                          all
                                                                           down* cmac0338
            up
                 infinite 1-infinite no
                                                          all
                                                                        draining cmac0533
normal
normal
                 infinite 1-infinite
                                                          all
                                                                         drained cmac[0059-0061,1304]
             up
                 infinite 1-infinite
                                                NO
                                                          all
normal
                                                                       allocated cmac[0037-0046,0062-0093,0530-0532,0534-0545,1122-1137,1530]
                                                NO
normal
             up infinite 1-infinite no
                                                          all
                                                                1423
                                                                            idle cmac[0035-0036,0047-0058,0094-0337,0339-0529,0546-1121,1138-1303,1305-1400,1402-1529,1531-1538]
normal
                 infinite 1-infinite
                                                NO
                                                          all
                                                                            down cmac1401
                 infinite 1-infinite
                                                          all
operation
            up
                                                NO
                                                                           down* cmac0338
            up infinite 1-infinite no
                                                NO
                                                          all
                                                                        draining cmac0533
operation
operation
                 infinite 1-infinite
                                                          all
                                                                        drained cmac[0059-0061,1304]
                 infinite 1-infinite
                                                                       allocated cmac[0037-0046,0062-0093,0530-0532,0534-0545,1122-1137,1530]
operation
                                                          all
                 infinite 1-infinite
                                                NO
                                                          all
operation
                                                                            idle cmac[0035-0036,0047-0058,0094-0337,0339-0529,0546-1121,1138-1303,1305-1400,1402-1529,1531-1538]
            up
                                                NO
operation
                 infinite 1-infinite no
                                                          all
                                                                            down cmac1401
                 infinite 1-infinite
                                                NO
                                                          all
                                                                           down* cmac0338
sgtest
                 infinite 1-infinite no
                                                NO
                                                          all
sqtest
             up
                                                                        draining cmac0533
satest
             up infinite 1-infinite no
                                                NO
                                                          all
                                                                         drained cmac[0059-0061]
                 infinite 1-infinite
                                                          all
                                                                 57 allocated cmac[0037-0046,0062-0093,0530-0532,0534-0545]
sgtest
                 infinite 1-infinite
                                                                            idle cmac[0035-0036,0047-0058,0094-0337,0339-0529,0546-0835]
[sghpc2@login04 ~]$
```

成就梦想



示例3: 查看分区的摘要信息(--summarize)。 等价于 sinfo -o "%9P %.5a %.10l %.16F %N"

```
[sghpc2@login04 ~]$sinfo --summarize
PARTITION AVAIL TIMELIMIT
                             NODES(A/I/O/T)
                                             NODELIST
serial
                  infinite
                                  1/19/0/20
                                             cmac[0011-0030]
             up
                             91/1407/6/1504
                                             cmac[0035-1538]
normal
                 infinite
             up
operation
                 infinite
                             91/1407/6/1504
                                             cmac[0035-1538]
             up
                                             cmac[0035-0835]
sgtest
             up
                  infinite
                               74/723/4/801
[sghpc2@login04 ~]$
```

示例4: 自定义分区摘要信息显示,添加CPU状态分布信息。 sinfo -o "%9P %.5a %.10l %.16F %.24C %N"

```
[root@login_a04 ~]# sinfo -o "%9P %.5a %.10l %.16F %.24C %N"
PARTITION AVAIL
                 TIMELIMIT
                             NODES(A/I/O/T)
                                                       CPUS(A/I/O/T)
                                                                      NODELIST
serial
                                                        20/748/0/768 cmac[0011-0034]
                  infinite
                                  16/8/0/24
             up
serial op
                  infinite
                                                        20/748/0/768 cmac[0011-0034]
                                  16/8/0/24
             up
largemem
                  infinite
                               194/32/0/226
                                                    6168/1064/0/7232
                                                                      cmac [0035-0260]
             up
normal
             up
                  infinite
                            1091/413/0/1504
                                                 34806/13322/0/48128
                                                                      cmac[0035-1538]
operation
                  infinite
                            1091/413/0/1504
                                                 34806/13322/0/48128
                                                                      cmac [0035-1538]
[root@login a04 ~]#
```



示例5: 查询分区的异常节点的基本信息(--list-reasons / -R)。 sinfo -o "%20E %9u %19H %N"

```
[sghpc2@login04 ~]$sinfo --list-reasons
REASON USER TIMESTAMP NODELIST
Low RealMemory slurmadm 2018-03-22T12:28:41 cmac1304
Not responding slurmadm 2018-03-27T10:05:36 cmac0338
IB_state20 root 2018-03-26T14:45:37 cmac0533
Low RealMemory slurmadm 2018-03-28T02:57:16 cmac[0059-0060]
Low RealMemory slurmadm 2018-03-28T02:59:06 cmac0061
Node unexpectedly re slurmadm 2018-03-26T09:45:15 cmac1401
[sghpc2@login04 ~]$
```

示例6: 查询分区的异常节点的详细信息(--long --list-reasons / -IR)。 sinfo -o "%20E %12U %19H %6t %N"

```
[sghpc2@login04 ~]$sinfo --long --list-reasons

Wed Mar 28 03:51:54 2018

REASON USER TIMESTAMP STATE NODELIST

Low RealMemory slurmadm(110 2018-03-22T12:28:41 drain* cmac1304

Not responding slurmadm(110 2018-03-27T10:05:36 down* cmac0338

IB_state20 root(0) 2018-03-26T14:45:37 drng cmac0533

Low RealMemory slurmadm(110 2018-03-28T02:57:16 drain cmac[0059-0060]

Low RealMemory slurmadm(110 2018-03-28T02:59:06 drain cmac0061

Node unexpectedly re slurmadm(110 2018-03-26T09:45:15 down cmac1401

[sghpc2@login04 ~]$
```

仍丁成就梦想



示例7: 自定义显示顺序 (--sort= / -S)。

排序表达式格式: [+|-]<key>,[+|-]<key>...

其中,+代表升序,-代表降序。此外,对于特殊的P,还可以是#,代表按照配置文件中的顺序显示。sinfo分区查询的默认排序方式为 "#P,-t"; sinfo节点查询的默认排序方式为"N"。

```
[sghpc2@login04 ~]$sinfo --sort="t"
PARTITION AVAIL TIMELIMIT NODES STATE NODELIST
normal
                 infinite
                               1 down cmac1401
                 infinite
                                   down cmac1401
operation
normal
                 infinite
                              16 idle cmac[0051-0058,0110-0114,0176-0178]
            up
serial
                 infinite
                              19 idle cmac[0012-0030]
satest
                 infinite
                                  idle cmac[0051-0058,0110-0114,0176-0178]
                                  idle cmac[0051-0058,0110-0114,0176-0178]
                 infinite
operation
normal
                 infinite
                            1481 alloc cmac[0035-0050,0062-0109,0115-0175,0179-0337,0339-0532,0534-1303,1305-1400,1402-1538]
                            1481 alloc cmac[0035-0050,0062-0109,0115-0175,0179-0337,0339-0532,0534-1303,1305-1400,1402-1538]
operation
                 infinite
            up
sgtest
                 infinite
                             780 alloc cmac[0035-0050,0062-0109,0115-0175,0179-0337,0339-0532,0534-0835]
serial
                 infinite
                                    mix cmac0011
            up
                               3 drain cmac[0059-0061]
normal
                 infinite
                 infinite
                               3 drain cmac[0059-0061]
sgtest
            up
operation
            up
                 infinite
                               3 drain cmac[0059-0061]
normal
            up
                 infinite
                               1 drng cmac0533
                               1 drng cmac0533
sqtest
                 infinite
                 infinite
                               1 drng cmac0533
operation
            up
                               1 down* cmac0338
normal
                 infinite
                 infinite
operation
            up
                               1 down* cmac0338
sqtest
            up
                 infinite
                               1 down* cmac0338
                 infinite
                               1 drain* cmac1304
normal
operation
            up
                 infinite
                               1 drain* cmac1304
[sghpc2@login04 ~]$
```



示例8: 组合示例-查询特定分区特定状态的节点状态信息。 sinfo -p P1,P2 -t T1,T2

```
[sghpc2@login04 ~]$sinfo -p operation,normal -t idle,alloc
PARTITION AVAIL TIMELIMIT NODES STATE NODELIST
normal
                infinite
                             1 drng cmac0533
normal
                infinite 1481 alloc cmac[0035-0050,0062-0109,0115-0175,0179-0337,0339-0532,0534-1303,1305-1400,1402-1538]
normal
               infinite
                             16 idle cmac[0051-0058,0110-0114,0176-0178]
operation
           up infinite
                            1 drng cmac0533
operation
           up infinite
                           1481 alloc cmac[0035-0050,0062-0109,0115-0175,0179-0337,0339-0532,0534-1303,1305-1400,1402-1538]
operation
           up infinite
                             16 idle cmac[0051-0058,0110-0114,0176-0178]
[sghpc2@login04 ~]$
```

SLURM作业-squeue



squeue:查询排队和运行状态的作业

参数	解释
-A,account=account(s)	查询指定账号的作业,默认全部账号下的作业
-j,job=job(s)	已逗号分隔指定显示的jobid,默认显示全部
-n,name=job_name(s)	逗号分隔指定的作业名称
-o,format=format	指定显示的信息
-p,partition=partition(s)	逗号分隔指定队列中的作业
-u,user=user_name(s)	逗号分隔指定用户的作业

[sugon@gpunode1 ~]\$	squeue				
JOBID I	PARTITION	NAME	USER ST	TIME	NODES NODELIST (REASON)
21	debug	sleep	sugon R	0:03	2 gpunode[1-2]





查看状态和配置命令 scontrol show < COMMAND>

COMMAND	解释
job	显示作业信息
node	显示节点信息
partition	显示队列信息
config	显示配置信息

SLURM队列-scontrol show



查询指定队列命令: scontrol show partition <name>

```
[root@gpunode2 ~]# scontrol show partition debug
PartitionName=debug
AllowGroups=ALL AllowAccounts=ALL AllowQos=ALL
AllocNodes=ALL Default=YES QoS=N/A
DefaultTime=NONE DisableRootJobs=NO ExclusiveUser=NO GraceTime=0 Hidden=NO
MaxNodes=UNLIMITED MaxTime=UNLIMITED MinNodes=1 LLN=NO MaxCPUsPerNode=UNLIMITED
Nodes=gpunode[1,2]
PriorityJobFactor=1 PriorityTier=1 RootOnly=NO ReqResv=NO OverSubscribe=NO
OverTimeLimit=NONE PreemptMode=OFF
State=UP TotalCPUs=80 TotalNodes=2 SelectTypeParameters=NONE
DefMemPerNode=UNLIMITED MaxMemPerNode=UNLIMITED
```

SLURM节点-scontrol show



查询指定节点: scontrol show node < name>

```
[root@gpunode2 ~] # scontrol show node gpunode1
NodeName=gpunode1 Arch=x86 64 CoresPerSocket=1
   CPUAlloc=0 CPUErr=0 CPUTot=40 CPULoad=0.37
  AvailableFeatures=(null)
  ActiveFeatures=(null)
  Gres=(null)
  NodeAddr=10.0.35.187 NodeHostName=gpunode1 Version=17.02
  OS=Linux RealMemory=30000 AllocMem=0 FreeMem=6194 Sockets=40 Boards=1
   State=IDLE ThreadsPerCore=1 TmpDisk=0 Weight=1 Owner=N/A MCS label=N/A
   Partitions=debug, nvidia2
   BootTime=2017-08-07T11:49:16 SlurmdStartTime=2017-08-22T15:23:13
  CfqTRES=cpu=40,mem=30000M
  AllocTRES=
  CapWatts=n/a
  CurrentWatts=0 LowestJoules=0 ConsumedJoules=0
   ExtSensorsJoules=n/s ExtSensorsWatts=0 ExtSensorsTemp=n/s
```

SLURM作业-scontrol show



查询指定作业: scontrol show job

```
[root@gvl1 ~]# scontrol show job
JobId=119 JobName=sleep
   UserId=sugon(1000) GroupId=docker(1000) MCS label=N/A
   Priority=4294901738 Nice=0 Account=physics QOS=testpartitiongos
   JobState=FAILED Reason=NonZeroExitCode Dependency=(null)
   Requeue=1 Restarts=0 BatchFlag=0 Reboot=0 ExitCode=1:0
   RunTime=00:00:00 TimeLimit=UNLIMITED TimeMin=N/A
   SubmitTime=2017-08-24T20:23:07 EligibleTime=2017-08-24T20:23:07
   StartTime=2017-08-24T20:23:07 EndTime=2017-08-24T20:23:07 Deadline=N/A
   PreemptTime=None SuspendTime=None SecsPreSuspend=0
   Partition=nvidia AllocNode:Sid=qv11:4295
   ReqNodeList=(null) ExcNodeList=(null)
  NodeList=qv11
   BatchHost=qv11
  NumNodes=1 NumCPUs=1 NumTasks=0 CPUs/Task=1 ReqB:S:C:T=0:0:*:*
   TRES=cpu=1,node=1
   Socks/Node=* NtasksPerN:B:S:C=0:0:*:* CoreSpec=*
  MinCPUsNode=1 MinMemoryNode=0 MinTmpDiskNode=0
   Features=(null) DelayBoot=00:00:00
   Gres=(null) Reservation=(null)
   OverSubscribe=OK Contiguous=O Licenses=(null) Network=(null)
   Command=sleep
  WorkDir=/home/sugon
   Power=
```

SLURM配置-scontrol show



查询配置: scontrol show config

```
[root@gvll ~]# scontrol show config
Configuration data as of 2017-08-24T20:24:16
AccountingStorageBackupHost = (null)
AccountingStorageEnforce = associations, limits
AccountingStorageHost
                        = qv11
                        = slurm acc
AccountingStorageLoc
AccountingStoragePort
                        = 3309
AccountingStorageTRES
                        = cpu, mem, energy, node
AccountingStorageType
                        = accounting storage/mysql
AccountingStorageUser
                        = root
AccountingStoreJobComment = Yes
AcctGatherEnergyType
                        = acct_gather_energy/none
AcctGatherFilesystemType = acct_gather_filesystem/none
AcctGatherInfinibandType = acct gather infiniband/none
AcctGatherNodeFreq
                        = 0 sec
AcctGatherProfileType
                        = acct_gather_profile/none
AllowSpecResourcesUsage = 0
                        = (null)
AuthInfo
AuthType
                        = auth/munge
                        = (null)
BackupAddr
BackupController
                        = (null)
BatchStartTimeout
                        = 10 sec
                        = 2017-08-22T20:37:29
BOOT TIME
BurstBufferType
                        = (null)
CacheGroups
                        = checkpoint/none
CheckpointType
ChosLoc
                        = (null)
```

携手成就梦想

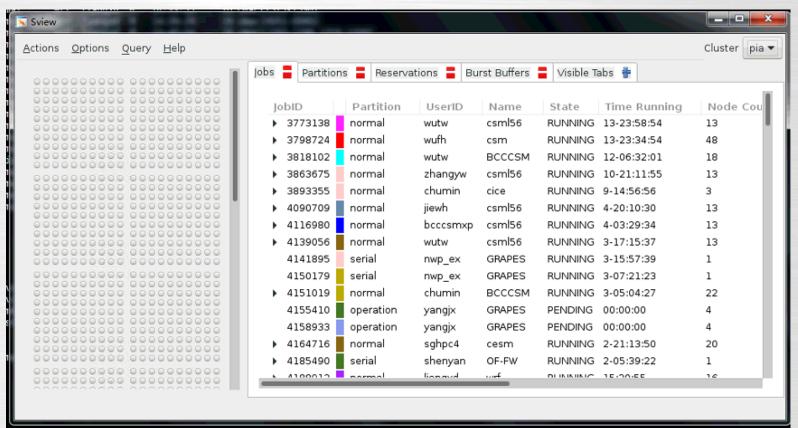
smap命令



```
Mon Oct 29 06:15:51 2018
ID JOBID
              PARTITION USER
                                      TIME NODES NODELIST
                          NAME
                                           48 cmac[0515-0526,0531-0562,0607-0610]
              normal
                                           18 cmac[0748,0792,0794-0795,0797,0830-0834,0851,0855,0858,1139,1141,1143,1147,1149]
 3818102
              normal
                          BCCCSM
                                R12-06:30:58
                    wutw
                    zhangyw
chumin
                                 R 9-14:55:53
                                            3 cmac[1160,1165-1166]
              normal
 4090709
                          csml56
                                R 4-20:09:27
                                           13 cmac[0995-1007]
              normal
                    jiewh
                                           13 cmac[0464-0466,0690,0751,1413-1414,1416-1417,1531-1533,1538]
 4141895
                    nwp_ex GRAPES
                                 R 3-15:56:36
                                            1 cmac0011
              serial
                                           22 cmac[0339-0354,0357-0358,1435-1438]
              normal
                    chumin BCCCSM
                                R 3-05:03:24
 4164716
              normal
                    sqhpc4 cesm
                                 R 2-21:12:47
                                           20 cmac[0035-0050,0115-0116,0123-0124]
                    liangxd wrf
                                           16 cmac[1251-1266]
              normal
                    liangxd wrf
                                           16 cmac[1499-1514]
              normal
                                   15:18:54
                    liangxd wrf
                                           16 cmac[0675-0689,0752]
              normal
 4188917
              normal
                    liangxd wrf
                                 R 14:50:36
                                           16 cmac[0127-0128,0147-0157,0160-0162]
                                           16 cmac[1283-1296.1319-1320]
                    liangxd wrf
              normal
                                    14:44:04
                                           16 cmac[0051-0066]
                    liangxd wrf
              normal
              normal
                    liangxd wrf
                                           16 cmac[1091-1103,1105-1106,1177]
 4188923
                    liangxd wrf
                                 R 14:31:34
                                           16 cmac[0893-0894,0915-0928]
              normal
```

sview命令





携手成就梦想

SLURM-提交作业



srun

交互式作业提交

sbatch

批处理作业提交

salloc

节点资源获取

SLURM-提交作业参数



常用的作业提交参数,适用于上述三种作业提交方式。

参数解释
指定作业名称
指定队列资源
指定节点数量
指定处理器数量
指定stdout的输出文件。如果指定的文件已经存在,它将被覆盖。
指定stderr的输出文件。如果指定的 文件已经存在,它将被覆盖。

SLURM-srun



例:提交请求2个节点的并且指定作业的名称为job1



SLURM-sbatch



```
[sugon@gpunode1 ~]$ sbatch -n 4 sleep.job //sbatch 只接收脚本 Submitted batch job 19
```

```
[sugon@gpunode1 ~]$ cat sleep.job //脚本格式示例
#!/bin/bash
                   //指定作业名
#SBATCH -J sleep
                   //指定队列
#SBATCH -p debug
                   //指定运行时间(分钟)
#SBATCH --time=1
                   //请求节点数
#SBATCH -N 2
                   //请求核心数
#SBATCH -n 2
#SBATCH -o logs/%j.sleep //标准输出文件
#SBATCH -e logs/%j.sleep //错误输出文件
echo ${SLURM JOB NODELIST}
                        作业占用节点列表
                        开始时间
echo start on $(date)
                        执行命令
sleep 100
                        结束时间
echo end on $(date)
```

SLURM-salloc



```
[root@gv11~]# salloc -n 4 //获取资源
salloc: Granted job allocation 117 //提交作业成功
[root@gv11~]# sleep 10 & //执行命令
[1] 1020
[root@gv11~]# exit //作业退出
exit
salloc: Relinquishing job allocation 117 //作业资源释放
[root@gv11~]#
```

SLURM-命令sacct的参数



sacct: 查询作业

参数	解释
-E,endtime=end_time	查询在指定时间之前,任何状态的作业·如果通过-s参数指定状态则返回在此时间之前的指定状态的作业,有效格式为:HH:MM[:SS] [AM PM] MMDD[YY] or MM/DD[/YY] or MM.DD[.YY] MM/DD[/YY]-HH:MM[:SS] YYYY-MM-DD[THH:MM[:SS]]
-S,starttime= starttime	在指定时间后,任何状态的作业
-T,truncate	如果一个job在starttime之前开始运行,开始时间将被截断 为starttime,同样的作业结束时间 =endtime
-o,format	指定显示字段以逗号分隔

SLURM-命令sacct示例

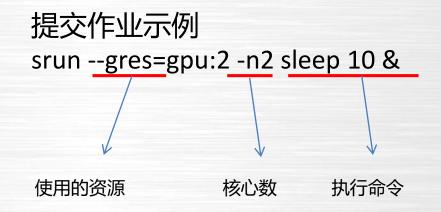


	1 ~]# sacct -S bID JobName			24 AllocCPUS	State	ExitCode
2	sleep	nvidia	physics	1	COMPLETED	0:0
3	sleep.job	nvidia	physics	1	COMPLETED	0:0
3.batch	batch		physics	1	COMPLETED	0:0
4	sleep	nvidia	physics	1	COMPLETED	0:0
5	sleep	nvidia	physics	1	COMPLETED	0:0
6	sleep	nvidia	physics	1	COMPLETED	0:0
7	sleep	nvidia	physics	1	COMPLETED	0:0
8	sleep10	nvidia	physics	1	FAILED	2:0
9	sleep10	nvidia	physics	1	FAILED	2:0

携手成就梦想

SLURM-GPU请求示例





作业脚本示例1—串行作业示例



串行作业的提交示例如右图所示:

示例中, calc_serial是一个串行程序,接收一个输入参数i,计算从0到 (i-1) 之间整数的和。

提交串行作业时,可以通过srun执行, 也可以在脚本中直接调用可执行程序。

```
#!/bin/bash

#SBATCH -J TestSerial

#SBATCH -p serial

#SBATCH -N 1

#SBATCH -n 1

#SBATCH -o log/%j.loop

#SBATCH -e log/%j.loop

#SBATCH --comment=CALMET
```

echo "SLURM_JOB_PARTITION=\$SLURM_JOB_PARTITION" echo "SLURM_JOB_NODELIST=\$SLURM_JOB_NODELIST"

srun ./calc serial 1000000

作业脚本示例2—MPI作业



简化的MPI作业脚本示例如右图所示:

示例中, calc_mpi是一个MPI并行程序,接收一个输入参数i, 计算从0到 (i-1) 之间整数的和。

提交作业时,建议通过srun启动; 需要注意,如果使用intelmpi,需要事先 按照示例设置I_MPI_PMI_LIBRARY变量;否 则作业无法在节点内并行。 #!/bin/bash #SBATCH -J mpi #SBATCH -p normal #SBATCH -N 2 #SBATCH -n 64 #SBATCH -o log/%j.loop #SBATCH -e log/%j.loop #SBATCH -comment=WRF

module load compiler/intel/composer_xe_2017.2.174 module load mpi/intelmpi/2017.2.174

export I_MPI_PMI_LIBRARY=/opt/gridview/slurm17/lib/libpmi.so srun ./calc_mpi 1000000

作业脚本示例3—单节点OpenMP作业



简化的OpenMP作业脚本示例如右图所示:

示例中, calc_openmp_init是一个单纯的OpenMP程序,接收一个输入参数i,计算从0到 (i-1) 之间整数的和。

提交作业时,建议通过srun启动; 需要注意,OpenMP类型的程序,需要 事先设置变量OMP_NUM_THREADS,控制 单进程的并发线程数。 #!/bin/bash
#SBATCH -J openmp
#SBATCH -p normal
#SBATCH -N 1
#SBATCH -n 1
#SBATCH -cpus-per-task=32
#SBATCH -o log/%j.loop
#SBATCH -e log/%j.loop
#SBATCH -comment=WRF

module load compiler/intel/composer_xe_2017.2.174

export OMP_NUM_THREADS=32 srun ./calc_openmp_init 1000000

作业脚本示例4—MPI/OpenMP



简化的MPI/OpenMP作业脚本,示例如 右图所示:

示例中, calc_openmp_init是一个单纯的OpenMP程序,接收一个输入参数i,计算从0到 (i-1) 之间整数的和。

提交作业时,建议通过srun启动; 需要注意,OpenMP类型的程序,需要 事先设置变量OMP_NUM_THREADS,控制 单进程的并发线程数。 #!/bin/bash
#SBATCH -J openmp_mpi
#SBATCH -p normal
#SBATCH -N 2
#SBATCH -n 4
#SBATCH --tasks-per-node=2
#SBATCH -cpus-per-task=16
#SBATCH -o log/%j.loop
#SBATCH -e log/%j.loop
#SBATCH -comment=WRF

module load compiler/intel/composer_xe_2017.2.174 module load mpi/intelmpi/2017.2.174

export OMP_NUM_THREADS=16 srun ./calc_openmp_mpi 1000000

作业脚本示例—气候模式



```
#!/bin/bash
```

#SBATCH -J MOD_01

#SBATCH -o log/%j.loop

#SBATCH -e log/%j.loop

#SBATCH --mem=2G

#SBATCH -p debug

#SBATCH -n 13 -N 1

#SBATCH -c 2

#SBATCH packjob

#SBATCH -J MOD_02

#SBATCH -p debug

#SBATCH --mem=2G

#SBATCH -n 2 -N 1

#SBATCH -c 1

#SBATCH packjob

#SBATCH --mem=2G

#SBATCH -J MOD_03

#SBATCH -p debug

#SBATCH -n 1 -N 1

#SBATCH -c 2

echo "SLURM_JOB_NODELIST=\${SLURM_JOB_NODELIST}" echo "SLURM_NODELIST=\${SLURM_NODELIST}"

module load compiler/intel/composer_xe_2018.1.163 module load mpi/intelmpi/2018.1

export I_MPI_PMI_LIBRARY=/opt/gridview/slurm17/lib/libpmi.so

for 16 proc, srun 10000000 = 74 sec runtime=100000000

#export OMP_NUM_THREADS=2

time srun --label --mpi=pmi2 --export=OMP_NUM_THREADS=2,ALL ./calc_openmp \$runtime : --export=OMP_NUM_THREADS=1,ALL ./calc_openmp2 \$runtime : --export=OMP_NUM_THREADS=2,ALL ./calc_openmp3 \$runtime

注意事项:

- 1. 各模块的作业描述以#SBATCH packjob行分隔;
- 2. 各模块的作业分别指定自己的描述信息;
- 3. 各模块的启动需要借助srun,各模块的启动命令以":"分隔;
- 4. 各模块如需指定不同同一环境变量的不同取值,则该变量**不能**在srun之前指定默认值,必须要在srun中的各个模块中通过—export=<var=x,ALL>分别指定,如OMP NUM THREADS。

作业脚本示例—作业依赖关联



普通用户提交作业时可以指定作业之间的 依赖关系,通过各种逻辑关系的设置来完成 一个复杂的业务处理流程。

常用的逻辑关系包括: after (依赖作业 开始运行时)、afterok (依赖作业正常结束 时)、afterany (依赖作业均完成)、 afternotok (依赖作业非正常结束)。

如下例所示:提交A、B、C三个作业,其依赖关系为:B作业需要在A作业正常结束后才能运行,C作业需要在作业B正常完成后开始。

```
编写业务脚本
    [test@gvm03 cma]# vim depdencysubmit
#! /bin/bash
AJobId=`sbatch JobA.slurm | awk '{print $4}'`
if [ $? -ne 0 ]; then
               echo "Failed to submit JobA slurm"
               exit 1
fi
BJobId=`sbatch --dependency=afterok:$AJobId JobB.slurm | awk '{print
$4}'`
if [ $? -ne 0 ]; then
               echo "Failed to submit JobB.slurm"
               exit 1
CJobId=`sbatch --dependency=afterok:$BJobId JobC.slurm | awk '{print
$4}'`
if [ $? -ne 0 ]; then
               echo "Failed to submit JobC.slurm"
               exit 1
```

作业脚本示例—作业依赖关联 查看JOBID 56作业的详细信息



```
提交业务脚本
```

bash depdencysubmit

查看作业运行状态

squeue

JOBID PARTITION NAME **USER ST** TIME NODES NODELIST(REASON)

LOOP 1 (Dependency) 57 debug root PD 0:00 0:00 debug LOOP root PD 1 (Dependency)

1 cmac0178 56 debug LOOP root R 0:02

UserId=root(0) GroupId=root(0) MCS label=N/A Priority=1 Nice=0 Account=root QOS=normal JobState=COMPLETED Reason=None Dependency=(null) Requeue=1 Restarts=0 BatchFlag=1 Reboot=0 ExitCode=0:0 RunTime=00:00:31 TimeLimit=UNLIMITED TimeMin=N/A

SubmitTime=2018-01-09T18:06:16 EligibleTime=2018-01-09T18:06:16 StartTime=2018-01-09T18:06:17 EndTime=2018-01-09T18:06:48

Deadline=N/A

scontrol show jobs 56 JobId=56 JobName=LOOP

PreemptTime=None SuspendTime=None SecsPreSuspend=0

LastSchedEval=2018-01-09T18:06:17 Partition=debug AllocNode:Sid=cmacm03:109650

RegNodeList=(null) ExcNodeList=(null)

NodeList=cmac0178

BatchHost=cmac0178

NumNodes=1 NumCPUs=10 NumTasks=10 CPUs/Task=1

ReaB:S:C:T=0:0:*:*

TRES=cpu=10,mem=1M,node=1,billing=10

Socks/Node=* NtasksPerN:B:S:C=0:0:*:* CoreSpec=*

MinCPUsNode=1 MinMemoryNode=1M MinTmpDiskNode=0

Features=(null) DelayBoot=00:00:00

Gres=(null) Reservation=(null)

OverSubscribe=OK Contiguous=0 Licenses=(null) Network=(null)

Command=/root/cma/JobA.slurm

WorkDir=/root/cma StdErr=/dev/null StdIn=/dev/null

StdOut=/dev/null

Power=

携手成就梦想

作业回填



启用回填策略

SchedulerType=sched/backfill

小作业回填大作业

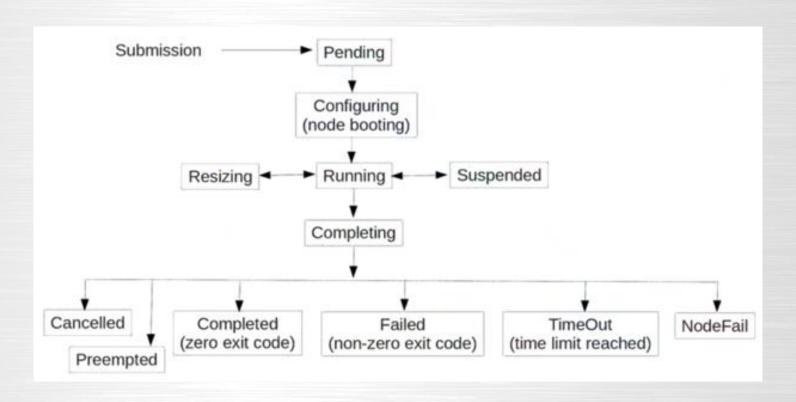
当前资源满足作业要求并且作业运行 时间较短的作业可以在不影响前面排队作 业启动的情况下调度运行,即回填生效 [sghpc2@gv178 \sim]\$ sbatch -N 2 -n 15 sleep.slurm Submitted batch job 54 [sghpc2@gv178 \sim]\$ sbatch -N 2 -n 32 sleep.slurm Submitted batch job 55

[sghpc2@gv178 ~]\$ sq	ueue						
JOBID P	ARTITION NAME	USER	ST	TIME	NODES	CPUS	START_TIME
_	NODELIST(REASON)						
	low HETE-MPI	sghpc2	PD	0:00	2	32	2018-11-16T08:55:39
2018-11-16T20:55:39	(Resources)						
		sghpc2	R	0:50	2	15	2018-11-15T20:55:39
2018-11-16T08:55:39	gv[11,178]						

```
[sghpc2@gv178 ~]$ sbatch -N 1 -n 10 -t 01:00:00 sleep.slurm
Submitted batch job 56
[sghpc2@gv178 ~]$ squeue
             JOBID PARTITION
                                          USER ST
                                                        TIME NODES
                                                                                    START TIME
           END TIME NODELIST(REASON)
                55
                         low HETE-MPI
                                        sghpc2 PD
                                                                        32 2018-11-16T08:55:39
                                                        0:00
2018-11-16T20:55:39 (Resources)
                         low HETE-MPI
                                        sghpc2 R
                                                                        15 2018-11-15T20:55:39
                54
                                                        1:34
2018-11-16T08:55:39 qv[11,178]
                         low HETE-MPI
                                        sqhpc2 R
                                                        0:00
                                                                        10 2018-11-15T20:57:13
2018-11-15T21:57:13 gv11
```

作业状态变化





目录



- 01 调度系统概述
- 02 安装部署介绍
- 03 用户使用介绍
- 04 日常管理介绍
 - ■服务控制
 - 作业管理
 - 节点管理
 - 分区管理
 - 账号管理

- QOS管理
- 用户管理
- 优先级管理
- 预约管理
- 作业前后处理

05 常见问题处理

服务控制



服务控制

服务启动

服务停止

查看服务状态

```
[root@cmacm03 ~]# systemctl start slurmctld
[root@cmacm03 ~]# echo $?
0
[root@cmacm03 ~]#
```

```
[root@cmacm03 ~]# systemctl stop slurmctld
[root@cmacm03 ~]# echo $?
0
[root@cmacm03 ~]#
```

```
[root@cmacm03 ~] # systemctl status slumctld

■ slumctld.service - Slum controller daemon
Loaded: loaded (/usr/lib/systemd/system/slumctld.service; enabled; vendor preset: disabled)
Active: active (running) since Mon 2018-01-22 04:03:20 UTC; lmin 41s ago
Process: 86072 ExecStart=/opt/gridview/slum17/sbin/slumctld $SLURMCILD_OPTIONS (code=exited, status=0/SUCCESS)
Main PID: 86075 (slumctld)
Tasks: 16 (limit: 5120)
CGroup: /system.slice/slumctld.service

—86075 /opt/gridview/slum17/sbin/slumctld

Jan 22 04:03:20 cmacm03 systemd[1]: Starting Slum controller daemon...
Jan 22 04:03:20 cmacm03 systemd[1]: Started Slum controller daemon...
Jan 22 04:03:20 cmacm03 systemd[1]: Started Slum controller daemon...
```

作业管理



scontrol: 控制作业命令

COMMAND	解释
scontrol suspend <jobid></jobid>	挂起作业
scontrol resume <jobid></jobid>	恢复作业
scontrol requeue <jobid></jobid>	作业重新排队
scontrol hold <id name=""></id>	保留作业
Scontrol release <id name=""></id>	释放作业

作业管理



[rootogy62	l# ccont	col cuchon	126				
[root@gv62 [root@gv62			1 120				
[100 ceg voz		ARTITION	NAME	USER ST	TIME	NODES	NODELIST(REASON)
	127	debug	L00P	root R	1:24		gv62
	128	debug	L00P	root R	1:24		gv62
	129	debug	L00P	root R	1:24		gv170
	130	debug	L00P	root R	1:24	1	gv170
	126	debug	L00P	root S	1:12	1	gv62
[root@gv62	~]# scont	rol resume	126				
[root@gv62	~]# squeue	9					
	JOBID PA	ARTITION	NAME	USER ST	TIME	NODES	NODELIST(REASON)
	127	debug	L00P	root R	1:34		gv62
	128	debug	L00P	root R	1:34		gv62
	129	debug	L00P	root R	1:34		gv170
	130	debug	L00P	root R	1:34		gv170
	126	debug	L00P	root R	1:13	1	gv62
[root@gv62			e 126				
[root@gv62							
		ARTITION	NAME	USER ST	TIME		NODELIST(REASON)
	126	debug	L00P	root PD	0:00	1	(Dependency)
[root@gv62			26				
[root@gv62							
		ARTITION	NAME	USER ST	TIME		NODELIST(REASON)
	126	debug	L00P	root PD	0:00	1	(JobHeldAdmin)
[root@gv62			2 126				
[root@gv62							
		ARTITION	NAME	USER ST	TIME		NODELIST(REASON)
	126	debug	L00P	root R	0:14	1	gv62

节点管理(1/2)



查询节点:

- (1) sinfo
- (2) sinfo -N

控制节点:

(1) 下线节点:

scontrol update nodename=gv21 state=drain reason="hardware error"

- (2) 上线节点 scontrol update nodename=gv21 state=idle
- (3) 节点清空 scontrol update nodename=gv21 state=down reason="debug"
- (4) 节点恢复 scontrol update nodename=gv21 state=resume

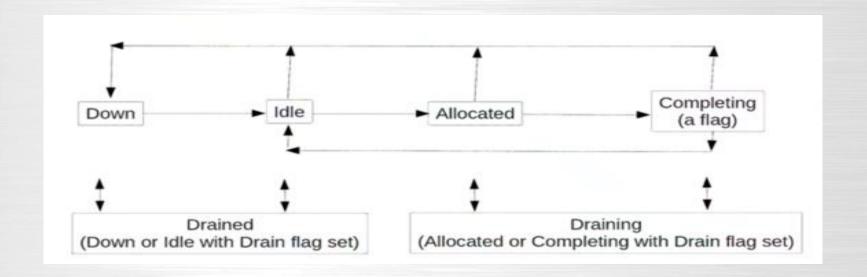
```
[zhangtao@gv21 cma]$ sinfo
PARTITION AVAIL TIMELIMIT
                            NODES
                                   STATE NODELIST
debug*
             up 3-00:00:00
                                     idle gv21
             up 3-00:00:00
                                     idle gv21
testq
singer
             up 3-00:00:00
                                    idle gv21
double
             up 3-00:00:00
                                    idle gv21
double2
                                     idle gv21
             up 3-00:00:00
[zhangtao@gv21 cma]$
```

```
[root@gv21 ~]#
[root@gv21 ~]# scontrol update nodename=gv21 state=down reason="debug"
[root@gv21 ~]# sinfo
PARTITION AVAIL TIMELIMIT NODES STATE NODELIST
             up 3-00:00:00
                                    idle gv21
estq
             up 3-00:00:00
                                    idle gv21
singer
             up 3-00:00:00
                                    idle gv21
double
             up 3-00:00:00
                                    idle gv21
double2
             up 3-00:00:00
                                    idle gv21
[root@gv21 ~] # squeue
             JOBID PARTITION
                                 NAME
                                           USER ST
                                                         TIME
                                                               NODES NODELIST (REASON)
                                                         0:00
               175
                              MEMTEST zhangtao PD
                                                                   1 (BeginTime)
```

节点管理(2/2)



状态转换图



分区管理(1/3)



查询分区:

sinfo -p debug

分区详情:

scontrol show partion debug

调整状态:

UP : 正常

DOWN : 接收不调度 DRAIN : 调度不接收 INACTIVE : DOWN+DRAIN

下线分区:

scontrol update
PartitionName=debug State=Down

上线分区:

scontrol update
PartitionName=debug State=Idle

```
[root@gv21 ~] # sinfo -p debug
PARTITION AVAIL TIMELIMIT NODES STATE NODELIST
debug* up 3-00:00:00 1 idle gv21
[root@gv21 ~] #
```

```
[root@gv21 ~]# sinfo
PARTITION AVAIL
                 TIMELIMIT
                            NODES
                                    STATE NODELIST
           down 3-00:00:00
iebug*
                                     idle qv21
testq
             up 3-00:00:00
                                     idle qv21
             up 3-00:00:00
                                     idle gv21
singer
double
             up 3-00:00:00
                                     idle gv21
double2
             up 3-00:00:00
                                     idle gv21
[root@gv21 ~]#
```

分区管理(2/3)



分区用户限制

通过设置分区的可访问账号进行 分区的用户限制,即只允许部分 用户使用分区。

分区配置:

AllowAccounts=ALL 所有账号均可以使用 AllowAccounts=accountName[,] 某些账号可以使用,如opea,nwp PartitionName=normal Nodes=cmac[0035-1538] Priority=1000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=ALL QOS=normal_qos Default Time=15-00:00:00 MaxTime=INFINITE DefMemPerCPU=5120 State=UP PartitionName=operation Nodes=cmac[0035-1538] Priority=2000 OverSubscribe=FORCE:1 Default=NO AllowAccounts=nwp,nwp_op,nwp_sp,lijuan,nwp_pd,nwp_qu,nwpbj_ex DefaultTime=15-00:00:00 MaxTime=INFINITE State=UP

分区管理(3/3)



作业抢占

通过设置队列的优先级实现队列间作业的抢占,高优先级队列资源不够时可以抢占低优先级队列作业资源。

PartitionName=low Nodes=ALL Default=YES MaxTime=INFINITE Priority=1000 DefaultTime=01:00:00 State=UP
PartitionName=middle Nodes=ALL Default=NO MaxTime=INFINITE Priority=2000 DefaultTime=01:00:00 State=UP
FartitionName=high Nodes=ALL Default=NO MaxTime=INFINITE Priority=3000 DefaultTime=01:00:00 State=UP

队列优先级参数: Priority=1000

slurm.conf 抢占设置

PreemptMode=requeue,gang #PreemptMode=cancel,gang #PreemptMode=suspend,gang PreemptType=preempt/partition_prio

```
[sghpc2@gv178 ~]$ squeue

JOBID PARTITION NAME USER ST TIME NODES CPUS START_TIME END_TIME NODELIST(REASON)

30 low HETE-MPI sghpc2 PD 0:00 1 3 2018-11-14T22:22:00 2018-11-14T23:22:00 (Nodes required for post are DOWN, DRAINED or reserved for jobs in higher priority partitions)

31 middle HETE-MPI sghpc2 PD 0:00 1 3 2018-11-14T21:22:31 2018-11-14T22:22:31 (Resources)

32 high HETE-MPI sghpc2 R 0:33 1 3 2018-11-14T20:22:31 2018-11-14T21:22:31 gv178
```

账号管理(1/2)

查询账户:

sacctmgr show account withassoc

添加账户:

sacctmgr add account acct03
[Parent=<root>]

修改账户:

sacctmgr modify account acct03 set GrpJobs=2 sacctmgr modify account acct03 set Parent=root

删除账号:

sacctmgr delete account acct03

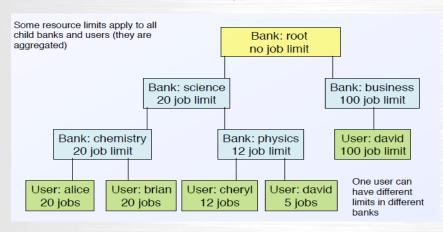


```
root@gv21 ~] # sacctmgr show accounts
  Account
                                                   Orq
   acct01
                         acct02
   acct02
                                                acct02
                         acct03
                                                acct03
     root default root account
                                                  root
root@gv21 ~] # sacctmgr modify accounts acct03 set GrpJobs=2
Modified account associations ...
                 A = acct03 of root
Would you like to commit changes? (You have 30 seconds to decide)
(N/y): y
[root@gv21 ~]#
```

账号管理(2/2)

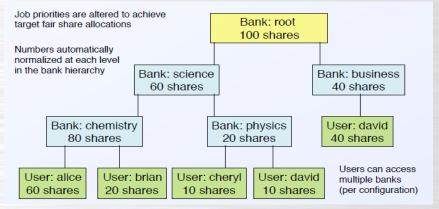
关联功能: 队列权限 公平共享 资源限制 记账统计

资源限制



公平共享





统计记账

[root@login	a01 ~1# sacc	t -A liangxd	-S 2018-1	0-29T12:00:	00 -F 2018-	-10-29T13:00:00
JobID		Partition		AllocCPUS		ExitCode
4188930	wrf	normal	liangxd	512	COMPLETED	Θ:Θ
4188930.bat+	batch		liangxd	32	COMPLETED	Θ:Θ
4188930.0	geogrid.e+		liangxd	32	COMPLETED	0:0
4188930.1	metgrid.e+		liangxd	64	COMPLETED	Θ:Θ
4188930.2	real.exe		liangxd	128	COMPLETED	0:0
4188930.3	gsi.exe		liangxd	128	COMPLETED	Θ:Θ
4188930.4	wrf.exe		liangxd	256	COMPLETED	0:0
4188930.5	gsi.exe		liangxd	128	COMPLETED	Θ:Θ
4188930.6	gsi.exe		liangxd	128	COMPLETED	0:0
4188930.7	gsi.exe		liangxd	128	COMPLETED	Θ:Θ
4188930.8	gsi.exe		liangxd	128	COMPLETED	0:0
4188930.9	geogrid.e+		liangxd	32	COMPLETED	Θ:Θ
4188930.10	metgrid.e+		liangxd	64	COMPLETED	0:0
4188930.11	real.exe		liangxd	128	COMPLETED	Θ:Θ
4188930.12	gsi.exe		liangxd	128	COMPLETED	0:0
4188930.13	wrf.exe		liangxd	256	COMPLETED	Θ:Θ

QOS管理



查询QOS:

sacctmgr show qos (normal是默认的用户QOS)

添加QOS:

sacctmgr add qos test_qos 修改QOS:

(分别设置单用户的运行作业数、 使用核心数、提交作业数) sacctmgr modify qos test_qos

set MaxJobsPerUser=4
sacctmgr modify qos test_qos
set MaxTRESPU="1=6"

sacctmgr modify qos test_qos set MaxSubmitJobsPerUser=6 (取消限制取值为-1)

删除QOS:

sacctmgr delete qos test_qos

		GraceTime	os Preempt PreemptMode TRESMins MaxWall	MaxTRESPU	MaxJobsPU	MaxSubmitPU	Flags UsageThres UsageFactor GrpTRES MaxTRESPA MaxJobsPA MaxSubmitPA !
normal	Θ	00:00:00	cluster	0200		200	1.000000
test_qos	100	00:00:00	cluster	cpu=8200	150	200	1.000000
special	Θ	00:00:00	cluster	10000		200	1.000000
normal_qos	Θ	00:00:00	cluster	cpu=40000	50	200	1.000000
operation	Θ	00:00:00	cluster		16	50	1.000000
sghpc2_qos	400	00:00:00	cluster	cpu=10240	200	500	1.000000
normal1	Θ	00:00:00	cluster	cpu=2000	40		1.00000
speciall	Θ	00:00:00	cluster	cpu=12300	50	200	1.000000
[root@login_a@	01 ~]#			cpu=8200	200	2100	

<pre>[root@login_a01 ~]# sacctmgr modify qos te Modified qos test_qos Would you like to commit changes? (You hav (N/y): y [root@login_a01 ~]# sacctmgr show qos test Name Priority GraceTime Preemp MaxTRES MaxTRESPerNode MaxTRESMin</pre>	e 30 seconds to decide) _qos t PreemptMode	Flags UsageThres UsageFactor GrpTRES bsPU MaxSubmitPU MaxTRESPA MaxJobsPA MaxSubmitPA	
test_qos 100 00:00:00 [root@login_a01 ~]#	cluster cpu=6	1.000000	

用户管理



查询用户:

sacctmgr show user withassoc

添加用户:

sacctmgr add user sghpc2
DefaultAccount=acct02
[QOS=test_qos] [Cluster=pia]

修改用户:

sacctmgr modify user sghpc2 set QOS=normal

删除用户:

sacctmgr delete user sghpc2

```
[root@gv021 etc] # sacctmgr add user sghpc2 DefaultAccount=acct02 QOS=test gos
There is no uid for user 'sghpc2'
Are you sure you want to continue? (You have 30 seconds to decide)
(N/y): y
Adding User(s)
  sghpc2
 Settings =
  Default Account = acct02
 Associations =
  U = sqhpc2
               A = acct02
                               C = qv021
  U = sqhpc2
               A = acct02
                               C = qv022
 Non Default Settings
                = test qos
Would you like to commit changes? (You have 30 seconds to decide)
(N/y): y
[root@gv021 etc]#
```

```
[root@gv021 etc] # sacctmgr modify user sghpc2 set DefaultAccount=acct03
Can't modify because these users aren't associated with new default account 'acct03'...
U = sghpc2 C = gv021
U = sghpc2 C = gv022
[root@gv021 etc]# sacctmgr modify user sghpc2 set QOS=normal
Modified user associations...
 C = qv021 A = acct02
                                      U = sghpc2
 C = gv022 A = acct02
                                      U = sahpc2
ould you like to commit changes? (You have 30 seconds to decide)
(N/v): v
root@gv021 etc]#
root@gv021 etc]# sacctmgr show users sghpc2 withassoc
     User Def Acct Admin Cluster Account Partition
                                                                Share MaxJobs MaxNodes MaxCPUs MaxSubmit
   sghpc2
             acct02
                        None
                                  gv021
                                                                                                                                              normal
   sghpc2
            acct02
                        None
                                  qv022
                                           acct02
                                                                                                                                              normal
 root@gv021 etc]#
```

优先级管理

系统支持两种优先级策略:

- 1. priority/basic
- 2. priority/multifactor

Multifactor权重参数:

- PriorityWeightAge
- PriorityWeightFairshare
- 3. PriorityWeightJobSize
- 4. PriorityWeightPartition
- 5. PriorityWeightQOS
- 6. PriorityWeightTRES

优先级修改:

scontrol update JobID=X Priority=Y 忧气优生级·

恢复优先级:

Scontrol hold X

Scontrol release X



Age factor:

排队时间/PriorityMaxAge

Job_size_factor:

(占用节点数/总节点数+占用核心数/总核心数) /2 partition factor:

分区JobFactor/最大分区Factor

QOS_factor

所用qos优先级/最大QOS优先级

Tres factor

作业CPU数/队列CPU数*权重+作业内存/队列总内存 *权重

预约管理



提交作业: sbatch -reservation=test3_ 1 test.slurm

创建资源预约:

(1)用root用户为test3用户创建一个包含gv0011节点的预留,如下所示:

[root@cmacm03 \sim]# scontrol create reservation user=test3 starttime=now duration =60 flags=maint,ignore_jobs nodes=cmac0011 Reservation created: test3_1

(2)查看预约

```
[root@cmacm03 ~]# scontrol show reservation
ReservationName=test3_1 StartTime=2018-01-22T02:54:33 EndTime=2018-01-22T03:54:
33 Duration=01:00:00
   Nodes=cmaco011 NodeCnt=1 CoreCnt=32 Features=(null) PartitionName=(null) Fla
gs=MAINT,IGNORE_JOBS,SPEC_NODES
   TRES=cpu=32
   Users=test3 Accounts=(null) Licenses=(null) State=ACTIVE BurstBuffer=(null)
Watts=n/a
```

(3)更新预约

```
[root@cmacm03 ~]# scontrol update ReservationName=test3_1 duration=120
Reservation updated.
You have new mail in /var/spool/mail/root
[root@cmacm03 ~]# scontrol show reservation
ReservationName=test3_1 StartTime=2018-01-22T02:54:33 EndTime=2018-01-22T04:54:
33 Duration=02:00:00
   Nodes=cmac0011 NodeCnt=1 CoreCnt=32 Features=(null) PartitionName=(null) Fla
gs=MAINT,IGNORE_JOBS,SPEC_NODES
   TRES=cpu=32
   Users=test3 Accounts=(null) Licenses=(null) State=ACTIVE BurstBuffer=(null)
Watts=n/a
```

(4)删除预约

[root@cmacm03 ~]# scontrol delete reservation=test3_1
[root@cmacm03 ~]# scontrol show reservation
No reservations in the system

携手成就梦想

预约管理



SLURM具备为USER/ACCOUNT的作业预留资源(如Cores、Nodes、Licenses)的功能。一般来说,资源预留至少包括如下3项关键属性:

- (1) 预留哪些资源;
- (2) 预留多少时间;
- (3) 为哪些用户预留。

预约仅仅可以被root用户或配置的SlurmUser使用scontrol命令进行创建,更新,删除。

资源预约参数:

ReservationName, StartTime, EndTime, Duration, Nodes, NodeCnt, CoreCnt, Features, PartitionName, Flags, TRES, Users, Accounts, Licenses, State

Flag参数:

maint: 为记账目的进行资源预约

ignore_jobs: 创建预约时忽视正在运行的作业

daily:每日预约overlap:预约重叠

scontrol create reservation user=sghpc2 starttime=now duration=60 flags=maint,ignore_jobs nodes=cmbc1513

作业前后处理



SLURM作业调度软件支持作业运行前后的脚 本运行

前处理脚本slurm.prolog 后处理脚本slurm.epilog

slurm.conf配置

Epilog=/opt/gridview/slurm17/etc/slurm.epilog Prolog=/opt/gridview/slurm17/etc/slurm.prolog

slurm.prolog
#!/bin/bash
date >> /tmp/prolog.\${SLURM_JOB_ID}.log

slurm.epilog
#!/bin/bash
date >> /tmp/epilog.\${SLURM_JOB_ID}.log

[root@cmac1451_a302r5n1 tmp]#cat prolog.2251239.log
Tue Jun 12 11:36:11 UTC 2018

[root@cmac1451_a302r5n1 tmp]#cat epilog.2251239.log Tue Jun 12 11:39:32 UTC 2018

目录



- 01 调度系统概述
- 02 安装部署介绍
- 03 用户使用介绍
- 04 日常管理介绍
- 05 常见问题处理

常见问题处理



1、节点维护

- (1) 下线节点: scontrol update nodename=gv21 state=drain reason="hardware error"
- (2) 上线节点: scontrol update nodename=gv21 state=idle

2、队列维护

- (1) 下线队列: 接收不调度 scontrol update PartitionName=debug State=Down 调度不接收 scontrol update PartitionName=debug State=Drain
- (2) 上线分区: scontrol update PartitionName=debug State=UP

常见问题处理



- 3、节点状态为down sinfo-R可以看到节点down和原因
 - (1) 查看计算节点munge服务是否正常 systemctl status munge.service
 - (2) 查看计算节点slurmd服务是否正常 systemctl status slurmd.service
- 4、节点状态为comp
- (1) 计算节点down scontrol update nodename=cmbc0646 state=down reason=comp
- (2) 计算节点恢复: scontrol update nodename=cmbc0646 state=resume

```
[root@cmbcm02 ~]# sinfo -R
REASON USER TIMESTAMP NODELIST
Not responding slurmadm 2018-11-14T11:09:11 cmbc0498
Not responding slurmadm 2018-11-14T09:07:31 cmbc0755
```

```
[root@cmbcm02 ~]# sinfo -t comp
PARTITION AVAIL
                                  STATE NODELIST
                TIMELIMIT NODES
serial
                  infinite
                                     n/a
serial op
             up
                 infinite
                                     n/a
largemem
             up
                 infinite
                                    n/a
normal
                 infinite
                                    comp cmbc[0646,0994]
             up
                                    comp cmbc[0646,0994]
                  infinite
operation
```

常见问题处理



5、节点状态为down

slurmd服务重启失败

处理: 查看slurm服务, 若有作业残留, 确认该作业已结束后, 强制删除残留作业, 重启slurmd服务正常。

```
[root@cmbc0852_b611r6n2 slurmd_spool]#ps -ef[grep slurm
root 3079 1 0 Nov03 ? 00:00:00 slurmstepd: [3157371.1]
slurmadm 15429 1 0 Jul05 ? 00:04:57 /opt/gridview/munge/sbin/munged --num-threads=10
root 65565 1 0 Sep26 ? 00:01:32 /opt/gridview/slurm17/sbin/slurmd
root 167225 166888 0 02:11 pts/0 00:00:00 grep --color=auto slurm
```



谢谢!

IT基础设施及方案的领导者 数据中国百城百行的发起者 中科院产业化联盟的推动者 安全可控信息系统的践行者

携手成就梦想